Evaluación Comparativa de Modelos Digitales de Elevación para la Estimación de Susceptibilidad a Inundaciones mediante Modelos Random Forest en la Cuenca Baja del Río Sinú

Sebastian Alfonso Velosa Bohorquez
Maestría en Geomática, Universidad Nacional de Colombia, Bogotá D.C, Colombia;

Octubre de 2026

RESUMEN

La disponibilidad de Modelos Digitales de Elevación (MDE) de calidad es un factor determinante para el modelamiento de la susceptibilidad a inundaciones en planicies aluviales de bajo relieve. Este estudio examina cómo el tipo de MDE impacta en la exactitud y estabilidad de las predicciones de susceptibilidad a inundaciones en la cuenca baja del Río Sinú (Colombia), empleando el algoritmo de Random Forest (RF). Se evaluaron tres productos globales de elevación con resolución espacial de 30 metros: Copernicus DEM (MDS), FABDEM (MDT) y ANADEM (MDT). En primer lugar, se realizó una evaluación altimétrica frente a 60 puntos de la Red de Control Vertical del Instituto Geográfico Agustín Codazzi (IGAC). Posteriormente, se derivaron nueve variables topográficas e hidrológicas para cada MDE y se entrenaron tres modelos de RF utilizando un inventario binario de inundaciones extraído de imágenes Sentinel-1 SAR. Los resultados altimétricos mostraron que Copernicus DEM presentó el menor sesgo medio (ME = -2,10 m), seguido de ANADEM (-2,59 m) y FABDEM (-3,07 m), con un RMSE global de ~20 m debido a inconsistencias en puntos de la periferia. En la clasificación mediante Random Forest, los tres modelos alcanzaron un desempeño alto y consistente para 5 configuraciones de hiperparametros, destacándose FABDEM con un ROC-AUC de 0,9304 y un F1-score de 0,8634, seguido de Copernicus DEM (ROC-AUC = 0,9255, F1 = 0,8736) y ANADEM (ROC-AUC = 0,9226, F1 = 0,8571). El análisis de importancia de variables reveló que la altura relativa al drenaje (HAND) y la elevación absoluta son los predictores más relevantes en todos los modelos. Se concluye que, aunque los MDT depurados mejoran la representación conceptual del terreno desnudo, los MDS de alta calidad como Copernicus DEM representan una alternativa sumamente viable y precisa para el mapeo de susceptibilidad a inundaciones en regiones con disponibilidad limitada de datos.

Palabras clave: Susceptibilidad a inundaciones, modelos digitales de elevación, variables topográficas, Random Forest, comparación de modelos digitales de elevación.

ABSTRACT

The availability of high-quality Digital Elevation Models (DEMs) is a key factor in modeling flood susceptibility in low-relief floodplains. This study examines how the type of DEM affects the accuracy and stability of flood susceptibility predictions in the lower Sinú River basin (Colombia), using the Random Forest (RF) algorithm. Three global elevation products with a spatial resolution of 30 meters were evaluated: Copernicus DEM (MDS), FABDEM (MDT), and ANADEM (MDT). First,

an altimetric evaluation was conducted against 60 points from the Vertical Control Network of the Agustín Codazzi Geographic Institute (IGAC). Subsequently, nine topographic and hydrological variables were derived for each DEM, and three RF models were trained using a binary flood inventory extracted from Sentinel-1 SAR imagery. The altimetric results showed that the Copernicus DEM had the lowest mean bias (ME = -2.10 m), followed by ANADEM (-2.59 m) and FABDEM (-3.07 m), with an overall RMSE of ~20 m due to inconsistencies in peripheral points. In Random Forest classification, all three models achieved high and consistent performance across five hyperparameter configurations, with FABDEM standing out with a ROC-AUC of 0.9304 and an F1-score of 0.8634, followed by Copernicus DEM (ROC-AUC = 0.9255, F1 = 0.8736) and ANADEM (ROC-AUC = 0.9226, F1 = 0.8571). The variable importance analysis revealed that height relative to drainage (HAND) and absolute elevation are the most significant predictors in all models. It is concluded that, although refined MDTs improve the conceptual representation of bare terrain, high-quality MDS such as the Copernicus DEM represent an extremely viable and accurate alternative for mapping flood susceptibility in regions with limited data availability.

Key words: Flood susceptibility, Digital Elevation Models, Topographic variables, Random Forest, DEM comparison

1. INTRODUCCIÓN

Las inundaciones constituyen uno de los fenómenos naturales más recurrentes y destructivos a nivel global. Sus efectos generan consecuencias significativas sobre las actividades humanas, incluyendo la pérdida de vidas, la afectación de infraestructura y sistemas de comunicación, así como cuantiosas pérdidas económicas (Al-Sheriadeh & Daqdouq, 2024; Hossain & Paul, 2019). Según la Organización Meteorológica Mundial (WMO) (2021), de 1971 al 2019, el 44 % de los desastres naturales registrados estuvieron asociados a inundaciones, y representaron el 31% de las pérdidas económicas totales. Por este motivo, resulta fundamental llevar a cabo estudios que permitan caracterizar estos eventos, delimitar las áreas de afectación e identificar las zonas de mayor susceptibilidad, facilitando la formulación de medidas eficaces para la mitigación del riesgo y la reducción del impacto social y económico en la población (Arora et al., 2025; Avila-Aceves et al., 2023).

Desde el enfoque de riesgo, la susceptibilidad a inundación se entiende como la predisposición que presenta un territorio a la ocurrencia de procesos de inundación debido a sus características físicas y ambientales (Kaya & Derin, 2023). A diferencia de conceptos como amenaza y vulnerabilidad, la susceptibilidad considera principalmente las condiciones biofísicas del terreno y los factores asociados a la ocurrencia del fenómeno, sin incorporar directamente los elementos expuestos ni el nivel potencial de afectación (UNDRR, 2016). (Khan et al., 2026).

La investigación sobre susceptibilidad a inundaciones ha tenido un avance importante a lo largo de las últimas décadas, desde análisis geomorfológicos básicos hacia modelos computacionales avanzados. El avance de los sistemas de información geográfica, las ciencias computacionales y las tecnologías de percepción remota permite integrar múltiples

variables espaciales y ambientales en los análisis de susceptibilidad (Gao et al., 2026). Entre las variables más utilizadas se encuentran la pendiente, la elevación, la distancia a cuerpos hídricos, la precipitación, el uso y cobertura del suelo, así como diferentes atributos geomorfométricos derivados de modelos digitales de elevación (Kaya & Derin, 2023).

Los modelos digitales de elevación MDE constituyen un insumo primordial para representar la geometría del terreno. Los MDE pueden clasificarse como Modelo Digital de Superficie (MDS) o Modelo Digital de Terreno (MDT), dependiendo de si incluye vegetación y estructura artificiales (MDS) o si solo representa el terreno desnuda (MDT) (Carrera-Hernández, 2021). La mayoría de los MDE globales de acceso libre derivados de sensores satelitales ópticos (como AW3D30) o de radar (como SRTM y Copernicus DEM) actúan de manera predeterminada como MDS, dado que capturan elementos de la superficie como las copas de la vegetación y las estructuras artificiales. Debido a que la calidad y precisión de estos modelos globales varía considerablemente según el tipo de paisaje y la aplicación específica, numerosos estudios han evaluado su desempeño comparativo para determinar el producto óptimo en diferentes contextos geomorfológicos (Helmy et al., 2026; Mesa-Mingorance & Ariza-López, 2020; Toledo Salgado et al., 2026).

Con la reciente disponibilidad de conjuntos de datos auxiliares sobre cobertura forestal y edificación, las técnicas de aprendizaje automático se han empleado de forma creciente para remover estos artefactos superficiales y generar MDT refinados que representan el terreno desnudo. En este ámbito destacan desarrollos globales como FABDEM (Bielski et al., 2024), el cual utiliza regresión mediante bosques aleatorios para corregir la vegetación y las edificaciones a partir del Copernicus DEM; no obstante, presenta limitaciones asociadas a posibles incoherencias en los datos auxiliares que pueden fragmentar o alterar la continuidad topográfica. A nivel regional, ANADEM se presenta como un MDT para América del Sur desarrollado a partir del Copernicus GLO-30 con resolución de 30 metros, diseñado específicamente para mitigar el sesgo causado por la vegetación. (Laipelt et al., 2024).

1.2 PROBLEMA

En los últimos años, el uso de modelos para estimar la susceptibilidad a inundaciones se ha incrementado debido al desarrollo de diversas técnicas de análisis de datos (Bathe & Patil, 2025). Entre estas se destacan los modelos de inteligencia artificial y los enfoques híbridos, los cuales han alcanzado altos niveles de exactitud en la predicción de áreas susceptibles a inundación basados en variables derivadas de MDE (Long et al., 2025; Riazi et al., 2023).

A pesar de la amplia utilización de modelos digitales de elevación en la evaluación de la susceptibilidad a las inundaciones, las diferencias entre los valores de altimetría pueden introducir diferencias en la representación del relieve y en el cálculo de variables topográficas derivadas (Carrera-Hernández, 2021). Estas diferencias podrían propagarse hacia los modelos de clasificación e influir tanto en su capacidad discriminatoria como en la contribución relativa de las variables predictoras. En este sentido, resulta pertinente evaluar hasta qué punto la selección de los datos de elevación condiciona los resultados de los modelos de

susceptibilidad, particularmente en planicies aluviales donde pequeñas variaciones altimétricas pueden representar diferencias importantes en las características del terreno.

De esta manera, este estudio trata de responder, ¿en qué medida las diferencias entre distintos modelos digitales de elevación y las variables derivadas de estas influyen en el desempeño de modelos de aprendizaje automático para la evaluación de la susceptibilidad a las inundaciones en la planicie aluvial del rio Sinú? Para ello se tiene por objetivo evaluar la influencia de tres diferentes modelos digitales de elevación en la generación de variables topográficas y en el en el desempeño de modelos Random Forest para la evaluación de la susceptibilidad a las inundaciones en la planicie aluvial del río Sinú.

2. MATERIALES Y MÉTODO

La metodología planteada para este trabajo se divide en dos partes. La primera parte consta de un procedimiento para evaluar las diferencias entre los datos provenientes de 3 modelos digitales de elevación, Copernicus DEM, FABDEM y ANAMEN, obtenidos en condiciones homogéneas, usando como referencia puntos de altura de la Red de Control Vertical del Instituto Geográfico Agustín Codazzi (IGAC). El estudio tendrá por área de estudio la cuenca baja del rio Sinú, ya que las características de la planicie aluvial resultan adecuadas para estimar diferencias de alturas mínimas entre los diferentes MDE.

La segunda parte, busca determinar cómo la capacidad predictiva de los modelos de susceptibilidad a inundaciones se ve afectada por la selección de datos provenientes de cada modelo digital de elevación. Para esto se diseñaron tres experimentos con modelos de aprendizaje automático, donde varía únicamente el conjunto de variables predictoras provenientes de los tres MDE. Así se podrá comparar el efecto de cada modelo digital de elevación en el desempeño del modelo de susceptibilidad final.

2.1 ÁREA DE ESTUDIO

El área de estudio determinada corresponde a la subcuenca hidrográfica del Bajo Sinú, localizada en el departamento de Córdoba, en el norte de Colombia (Figura 1). El área cuenta con 5867.71 km 2. La delimitación espacial se obtuvo a partir de un modelo vectorial hidrográfico y fue convertida a geometría continua para su uso en sistemas de información geográfica y procesamiento en Google Earth Engine (GEE). Todas las variables fueron recortadas a esta unidad hidrográfica.

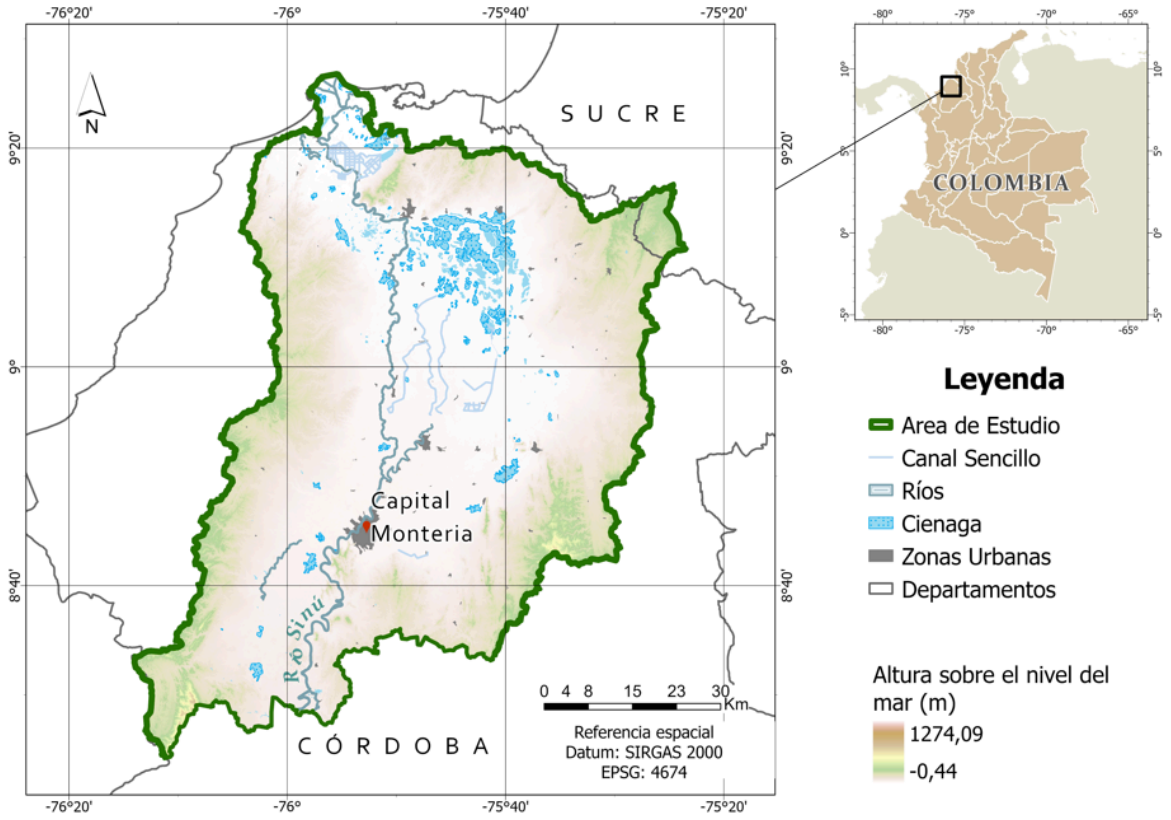


Figura 2. Localización del área de estudio.

2.2 COLECCIÓN DE DATOS

Esta sección detalla los conjuntos de datos utilizados que se describen en la Tabla 1.

2.2.1 Modelos digitales de elevación

Los modelos digitales de elevación (MDE) empleados en esta investigación corresponden a productos de cobertura global y regional, seleccionados para realizar una evaluación comparativa de la representación de la superficie y del terreno en la cuenca baja del río Sinú. Se utilizaron tres productos con resolución espacial nominal cercana a 30 m: Copernicus GLO-30, FABDEM V1-2 y ANADEM v1.0. Los datos se obtuvieron a través de Google Earth Engine (GEE) y de los repositorios oficiales de sus respectivos desarrolladores.

Copernicus GLO-30 es un modelo digital de superficie (MDS) derivado de datos de la misión TanDEM-X, cuya adquisición se realizó entre 2011 y 2015. Por su parte, FABDEM (Forest And Buildings removed Copernicus DEM) es un producto derivado de Copernicus GLO-30 que incorpora correcciones destinadas a reducir los sesgos de elevación asociados con la vegetación y las edificaciones, con el propósito de aproximarse a una representación del terreno desnudo. Finalmente, ANADEM v1.0 es un modelo digital del terreno (MDT) desarrollado por la Universidade Federal do Rio Grande do Sul (UFRGS) y la Agência

Nacional de Águas e Saneamento Básico (ANA) de Brasil, mediante procedimientos de corrección de las elevaciones asociadas con la cobertura vegetal.

Tabla 1. Características y función de las fuentes de información utilizadas para la construcción del inventario de inundaciones, la caracterización topográfica y la validación altimétrica.

	DATOS				
Características	**Copernicus DEM GLO-30**	**FABDEM V1-2**	**ANADEM v1.0**	**Red de Control Vertical IGAC**	**Sentinel-1 SAR**
Institución / entidad	Agencia Espacial Europea (ESA)	Universidad de Bristol	UFRGS / Agencia Nacional de Aguas de Brasil (ANA)	Instituto Geográfico Agustín Codazzi (IGAC)	Copernicus Data Space Ecosystem
Tipo de información	Modelo digital de superficie (DSM)	Modelo digital del terreno (DTM)	Modelo digital del terreno (DTM)	Puntos de control altimétrico	Imágenes de radar de apertura sintética (SAR)
Cobertura espacial	Global	Global	América del Sur	Colombia	Global
Resolución espacial	30 m	30 m aprox. (1 segundo de arco)	30 m aprox. (1 segundo de arco)	Puntual	10-20m
Unidad de elevación	Metros	Metros	Metros	Metros	--
Referencia horizontal original	WGS 84 (EPSG:4326)	WGS 84 (EPSG:4326)	SIRGAS 2000 (EPSG:4674)	MAGNA-SIR GAS (EPSG:4686	
Referencia vertical	EGM2008	EGM2008	Elipsoide WGS84 / geoide EGM2008	Datum vertical Buenaventura	
Método de generación	Interferometría radar TanDEM-X	Corrección de alturas de vegetación y edificios sobre Copernicus DEM	Corrección de sesgo de vegetación mediante machine learning sobre Copernicus DEM	Nivelación geodésica y ajuste de desniveles	
Variable principal	Elevación del terreno	Elevación del terreno	Elevación del terreno	Altura nivelada	Retrodispersión VV
Aplicación en la investigación	Comparación de elevaciones y derivación de variables topográficas	Comparación de elevaciones y derivación de variables topográficas	Comparación de elevaciones y derivación de variables topográficas	Validación altimétrica de los DEM	Identificación y delimitación de áreas inundadas

2.2.2 Información altimétrica de referencia

Adicionalmente, se utilizaron datos de la Red de Control Vertical del Instituto Geográfico Agustín Codazzi (IGAC), obtenidos de la plataforma Colombia en Mapas. Esta información, constituida por puntos de referencia altimétrica, se empleó como fuente de control para

evaluar las diferencias entre las elevaciones representadas por los modelos digitales y las alturas tomadas como referencias.

2.2.3 Imágenes de radar Sentinel-1

Para la identificación y delimitación de las áreas inundadas se utilizaron imágenes de radar de apertura sintética (SAR) del satélite Sentinel-1, perteneciente al programa Copernicus de la Agencia Espacial Europea (ESA). Se emplearon imágenes del producto Ground Range Detected (GRD), que proporciona información de retrodispersión en las polarizaciones VV, con una resolución espacial de 10 m.

2.3 MÉTODO

El diseño general del estudio se estructuró mediante un flujo de trabajo computacional compuesto por ocho fases, desarrolladas a través de siete cuadernos de programación (notebooks) en Python, utilizando Google Colab, y procesos de adquisición y procesamiento de datos en Google Earth Engine (GEE), mediante su entorno Code Editor. Los códigos, procedimientos y resultados asociados a cada etapa se encuentran documentados en el repositorio de GitHub del proyecto.

El flujo metodológico se divide en dos componentes principales. El primer componente, correspondiente a las fases 1 a 3, tiene como propósito evaluar la concordancia altimétrica de tres modelos digitales de elevación (ANADEM, Copernicus GLO-30 y FABDEM), utilizando como referencia las observaciones de la Red de Control Vertical de Precisión del Instituto Geográfico Agustín Codazzi (IGAC). Esta etapa comprende la preparación y armonización espacial de los datos, así como la comparación estadística de las elevaciones de cada modelo respecto a los puntos de control.

El segundo componente, desarrollado entre las fases 4 y 8, busca evaluar la influencia de las diferencias entre los modelos de elevación sobre el desempeño de los modelos de susceptibilidad a inundaciones. Para ello, se generan variables geomorfométricas derivadas de cada MDE, se preparan conjuntos de datos bajo criterios metodológicos comunes y se entrenan y evalúan modelos de clasificación mediante Random Forest.

La Figura 2 presenta el esquema general del flujo metodológico y la relación entre sus ocho fases.

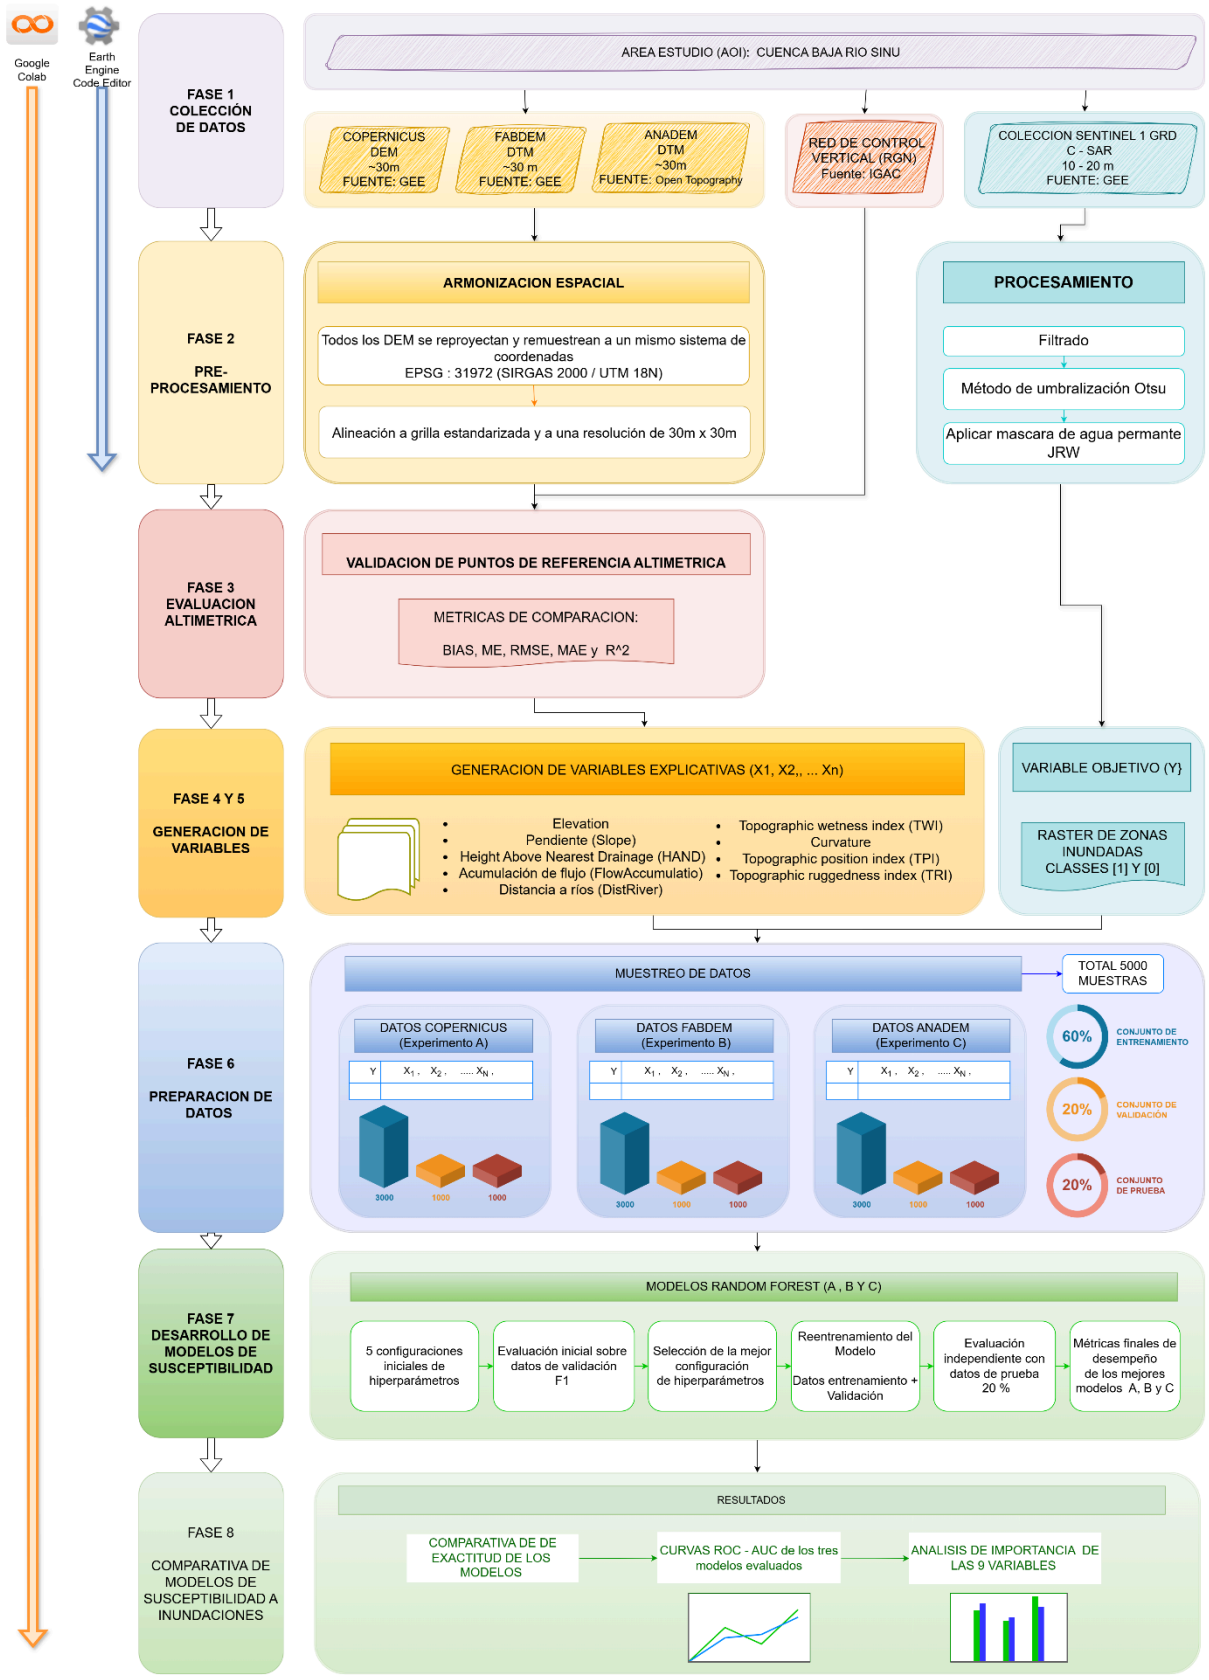


Figura 2. Flujo de trabajo

2.3.1 Parte 1. Evaluación de los modelos digitales de elevación

Fase 1. Inventario de DEM

Esta fase tiene por objetivo recopilar e importar los tres modelos digitales de elevación (MDE) seleccionados para el área de estudio: ANADEM, Copernicus GLO-30 y FABDEM. Los datos fueron obtenidos mediante Google Earth Engine (GEE), a través de la plataforma Code Editor, y posteriormente incorporados al entorno de Google Colab mediante la conexión con Google Drive

Cada modelo fue recortado al área de estudio y exportado en un sistema de referencia de coordenadas proyectado común, correspondiente a SIRGAS 2000 / UTM zona 18N (EPSG:31972). Como resultado de esta fase se obtuvieron tres archivos raster en formato GeoTIFF:

- ANADEM_Sinu.tif
- COPERNICUS_GLO30_Sinu.tif
- FABDEM_Sinu.tif

Fase 2. Armonización espacial

Esta fase tiene como proposito asegurar que los tres MDE, puedan ser comparados y utlizadas bajo condiciones homogeneas de resolucion, extension y alineacion de pixeles. Para ello, se construyó una cuadrícula de referencia regular sobre el área de estudio, independiente de los MDE originales, con un tamaño de píxel de 30 × 30 m. Esta cuadrícula definió la extensión espacial, el origen de coordenadas, la resolución y el sistema de referencia horizontal de los ráster resultantes, utilizando el sistema SIRGAS 2000 / UTM zona 18N (EPSG:31972). Adicionalmente, se verificó la compatibilidad de las referencias verticales de los modelos, considerando el datum vertical EGM2008 como referencia común.

El procedimiento de remuestreo se realizó mediante el método de interpolación bilineal (bilinear resampling), el cual estima el valor de cada píxel de salida a partir de una media ponderada de los cuatro píxeles más cercanos del raster original. Este método permite obtener una superficie continua de elevación y resulta apropiado para variables cuantitativas como la altitud.

Como resultado, se obtuvieron tres raster armonizados con idéntica resolución espacial, extensión, sistema de referencia y alineación de píxeles, garantizando la correspondencia entre las celdas de los diferentes modelos para las etapas posteriores de derivación de variables geomorfométricas.

Fase 3. Evaluación altimétrica

Esta fase tuvo como objetivo evaluar la concordancia altimétrica de los tres MDE mediante su comparación con observaciones independientes de la Red de Control Vertical de Precisión del Instituto Geográfico Agustín Codazzi (IGAC). Para la evaluación se seleccionaron 60 puntos de control vertical distribuidos en el área de estudio, cuya ubicación espacial se presenta en la Figura X. Estos puntos sirven de referencia independiente para analizar las diferencias entre las elevaciones registradas por los modelos y las alturas reportadas por la red de control. Para cada punto de control se extrajo el valor de elevación del píxel correspondiente en cada uno de los tres MDE armonizados.

Análisis gráfico

Se elaboraro un diagrama de dispersión donde se realiza la comparación entre las alturas estimadas por cada MDE y las alturas de referencia del IGAC. Se incorporó una línea de referencia 1:1 para identificar visualmente la concordancia entre ambas fuentes y posibles patrones de sobreestimación o subestimación.

Evaluación estadística de los errores

La evaluación cuantitativa se realizó mediante tres indicadores estadísticos, calculados a partir de las diferencias entre las elevaciones estimadas por los MDE y las alturas de referencia:

Tabla 2. Indicadores Estadísticos de error

Indicador	Descripción
ME (Mean Error)	Error medio o sesgo promedio. Permite identificar la tendencia sistemática del modelo.
MAE (Mean Absolute Error)	Error absoluto medio. Representa la magnitud promedio de las diferencias, sin considerar su signo.
RMSE (Root Mean Square Error)	Raíz del error cuadrático medio. Penaliza en mayor medida las diferencias de mayor magnitud.

Los indicadores se calcularon mediante las siguientes expresiones:

$$ME = \frac{1}{N}\sum_{L=1}^{N}\left(Z_{MDE_i} - Z_{R_i}\right) \qquad (1)$$

$$MAE = \frac{1}{N}\sum_{L=1}^{N}\left|Z_{MDE_i} - Z_{R_i}\right| \quad (2)$$

$$RMSE = \sqrt{\frac{1}{N}\sum_{L=1}^{N}\left(Z_{MDE_i} - Z_{R_i}\right)^2} \quad (3)$$

Donde:

- Z_{MDE_i}: elevación registrada por el modelo en el punto i
- Z_{R_i}: altura reportada por la Red de Control Vertical del IGAC.
- N: número de observaciones válidas.

Un ME cercano a cero indica una menor tendencia al sesgo sistemático; los valores positivos representan sobreestimación y los negativos subestimación. Por su parte, valores menores de MAE y RMSE indican una mayor concordancia altimétrica respecto a los puntos de referencia.

2.3.2 Parte 2. Evaluación de desempeño de modelos de susceptibilidad a inundaciones

Fase 4. Obtención de variables geomorfomètricas e hidrológicas

Esta fase se centra en obtener un conjunto de variables geomorfométricas e hidrológicas derivadas de los tres modelos digitales de elevación (ANADEM, Copernicus GLO-30 y FABDEM), con el propósito de caracterizar las diferencias en la representación del relieve y analizar su posible influencia en la modelación de la susceptibilidad a inundaciones

Derivados topográficos

A partir de las superficies de elevación armonizadas se calcularon cinco variables relacionadas con la configuración y las características morfológicas del terreno mediante operaciones de análisis raster implementadas en Python. Se consideraron los atributos de elevacion, pendiente (Slope),curvatura (Curvature), índice de posición topográfica (TPI) y rugosidad del terreno (TRI). Para el cálculo de los índices (TPI) y (TRI), se establecieron ventanas de vecindad de 11 × 11 y 3 × 3 píxeles, respectivamente. En el caso del TPI, la ventana representa un entorno aproximado de 330 m de ancho, mientras que para TRI se utilizó una vecindad local de 90 m de ancho.

Derivados hidrológicos

El procesamiento hidrológico de los modelos digitales de elevación se realizó mediante la biblioteca WhiteboxTools de Python. Inicialmente, se efectuó el acondicionamiento hidrológico de cada superficie mediante el algoritmo *Fill Depressions*, con el propósito de

corregir depresiones topográficas que pudieran interrumpir la continuidad del flujo superficial.

Posteriormente, se calculó la dirección de flujo mediante el algoritmo D8 y la acumulación de flujo (*Flow Accumulation*), expresada en número de celdas contribuyentes. La red de drenaje se extrajo utilizando un umbral de acumulación de 1000 celdas, aplicado de manera homogénea a los tres modelos de elevación. A partir de esta red y del MDE acondicionado se calculó el índice HAND (*Height Above Nearest Drainage*), que representa la diferencia vertical entre cada celda y la red de drenaje a la que se encuentra hidrológicamente conectada.

La distancia a la red hidrográfica (DistRiver) se calculó independientemente mediante una capa vectorial de drenaje denominada *Drenaje_Doble_clip.sh*p. Esta información se reproyectó al sistema de referencia de los MDE y posteriormente se rasterizó sobre la cuadrícula de análisis. A partir de las celdas correspondientes a la red hidrográfica se aplicó una transformación de distancia euclidiana, obteniendo la distancia desde cada celda hasta el elemento hidrográfico más cercano, expresada en metros

Fase 5 - Inventario de inundaciones

El inventario de inundaciones constituye la variable objetivo del modelo de susceptibilidad y fue construido a partir de imágenes SAR Sentinel-1 en modo IW de la colección COPERNICUS/S1_GRD disponible en Google Earth Engine. Se empleó principalmente la retrodispersión en banda C con polarizaciones VV, debido a su capacidad para discriminar superficies inundadas. Estos datos presentan una resolución espacial aproximada de 20 m y un ancho de barrido cercano a 250 km en modo IW.

Se generaron composiciones pre-inundación (diciembre de 2025) y post-inundación (febrero de 2026), a partir de las cuales se evaluaron cambios en la retrodispersión radar. El análisis exploratorio de datos evidencio que, en el histograma, los puntos de datos se concentran principalmente alrededor de -9 dB. Se observa un pequeño pico de valores bajos de retrodispersión alrededor de -22 dB; estos son los valores probables de zonas con presencia de agua. Luego se calculó el cambio de retrodispersión o backscatter por medio de la fórmula:

$$\Delta VV = VVpre - VVpost \qquad (4)$$

Posteriormente, se aplicó el método de Otsu de umbralizaciòn, para la determinación automática del umbral de clasificación y permitir la extracción de las superficies de agua. Para mejorar la precisión del inventario, se incorporó una máscara de agua permanente derivada del producto Global Surface Water (JRC), eliminando cuerpos de agua estables.

Fase 6 - Preparación de datos

Los tres conjuntos de variables geomorfométricas, correspondientes a ANADEM, Copernicus GLO-30 y FABDEM, se organizaron como estructuras raster multibanda de nueve variables explicativas. Posteriormente, se integraron con el inventario binario de inundaciones (*Flood*), que constituye la variable objetivo de clasificación.

Para garantizar la comparabilidad entre los modelos, se identificaron las celdas con información válida en los tres conjuntos de datos y con etiquetas correspondientes a las clases inundado (1) y no inundado (0). A partir de estas ubicaciones se seleccionó una muestra balanceada de 5.000 píxeles, compuesta por 2.500 observaciones de cada clase, mediante muestreo aleatorio sin reemplazo y utilizando una semilla fija para garantizar la reproducibilidad. Las mismas ubicaciones espaciales se utilizaron para extraer los valores de las nueve variables explicativas de cada MDE, generando tres bases de datos independientes en formato CSV, con idénticos identificadores, coordenadas y etiquetas de clasificación.

Finalmente, se estableció una partición estratificada común de los datos en tres subconjuntos: entrenamiento (60 %), validación (20 %) y prueba (20 %). Esta partición se realizó una sola vez y se reutilizó en los tres conjuntos de datos, garantizando que los modelos fueran entrenados y evaluados sobre las mismas observaciones espaciales.

Tabla 3. Divisiones del conjunto de muestras

Conjunto de Datos	**CLASES DE DATO DE INUNDACIÓN**		**Total**
	No inundado - 0	**Inundado - 1**	
Prueba	500	500	1000
Entrenamiento	1500	1500	3000
validación	500	500	1000
Total	2500	2500	5000

Fase 7. Comparación de modelos

El objetivo de esta fase fue evaluar si las diferencias entre los modelos digitales de elevación (MDE) Copernicus GLO-30, FABDEM y ANADEM influyen en el desempeño de los modelos de susceptibilidad a inundaciones. Para ello, se diseñaron tres experimentos basados en el algoritmo Random Forest, diferenciados por el conjunto de variables predictoras utilizado:

Diseño de los experimentos

- Experimento A: variables predictoras derivadas de Copernicus GLO-30.
- Experimento B: variables predictoras derivadas de FABDEM.
- Experimento C: variables predictoras derivadas de ANADEM.

Para garantizar la comparabilidad, se mantuvieron constantes las etiquetas del inventario de inundaciones, las observaciones seleccionadas, el esquema de muestreo, las particiones de los datos y el procedimiento de ajuste de hiperparámetros. De esta manera, la principal diferencia entre los experimentos correspondió a los valores de las variables predictoras derivados de cada MDE.

Los tres modelos se entrenaron y evaluaron utilizando las mismas particiones de datos: entrenamiento (60 %), validación (20 %) y prueba (20 %). El conjunto de entrenamiento se utilizó para ajustar los modelos, mientras que el de validación se destinó a la selección de hiperparámetros. Finalmente, el conjunto de prueba, que permaneció reservado durante estas etapas, se utilizó para realizar la evaluación final del desempeño de cada experimento.

Optimización de hiperparámetros

Para la construcción de los modelos de clasificación Random Forest se realizó una búsqueda de hiperparámetros con el propósito de identificar las configuraciones que proporcionan el mejor desempeño predictivo para cada conjunto de experimentos A,B y C con variables derivadas de FABDEM, Copernicus DEM y ANADEM. Para cada conjunto de variables derivadas de FABDEM, Copernicus DEM y ANADEM se evaluaron cinco configuraciones de hiperparámetros del algoritmo Random Forest.

Se consideraron variaciones en el número de árboles (300 y 500), la profundidad máxima de los árboles (sin límite, 20 y 30 niveles) y el número mínimo de observaciones por hoja (1, 2 y 5). El parámetro max_features se mantuvo constante en sqrt, mientras que class_weight se estableció en None, considerando el balance de las clases en las muestras utilizadas (50/50).

La selección de hiperparámetros se realizó mediante el entrenamiento de cada configuración con el conjunto de entrenamiento (60 %) y su posterior evaluación sobre el conjunto de validación (20 %). Se calcularon las métricas Accuracy, Balanced Accuracy, Precision, Recall, F1-score y ROC-AUC. Se seleccionó la configuración que obtuvo el mayor F1-score, tomando como referencia la clase inundada.

Una vez seleccionados los hiperparámetros, cada modelo fue entrenado nuevamente utilizando conjuntamente los datos de entrenamiento y validación (80 % de las muestras). Finalmente, el desempeño de los modelos se evaluó con el conjunto de datos de pruebas independiente (20 %), mediante las mismas métricas de clasificación. Este procedimiento se aplicó de manera equivalente a los tres conjuntos de datos, permitiendo comparar su desempeño bajo condiciones metodológicas comunes.

Fase 8. Evaluación de desempeño

Una vez seleccionados los parámetros, se ajusta cada modelo con entrenamiento y validación juntos. Después se calcula el desempeño en el test reservado. Evaluación final en test con accuracy, balanced accuracy, precision, recall, F1 y ROC-AUC.

El desempeño de los modelos se evaluó mediante las métricas Accuracy, Balanced Accuracy, Precision, Recall, F1-score y ROC-AUC. Estas métricas permitieron analizar tanto el comportamiento general de la clasificación como la capacidad específica de identificar las zonas inundadas.

Los resultados se compararon entre los tres modelos para determinar las diferencias en su capacidad de clasificación y evaluar la influencia de la fuente de elevación utilizada en la generación de las variables predictoras.

3. RESULTADOS

3.1 Parte 1. Comparación de los DEM en condiciones homogéneas

3.1.1 Comparabilidad geométrica

Cada raster se evaluó utilizando la misma resolución estándar de 30 metros x 30 metros, el sistema de coordenadas proyectado trabajado fue el SIRGAS 2000 / UTM 18N - EPSG:31972. La extensión en Píxeles dentro del AOI es de 6 519 713, que es el mismo valor de pixeles válidos para los DEM Copernicus y FABDEM, el DEM de ANADEM registró menor cantidad de píxeles válidos dentro del AOI, un total de 6 518 932.

Los valores de altura para cada punto de referencia se compararon con cada valor de elevación correspondiente en cada raster DEM, manteniendo la misma ubicación espacial. El siguiente histograma revela las frecuencias de los valores de altura para los 60 datos de la red de control vertical del IGAC.

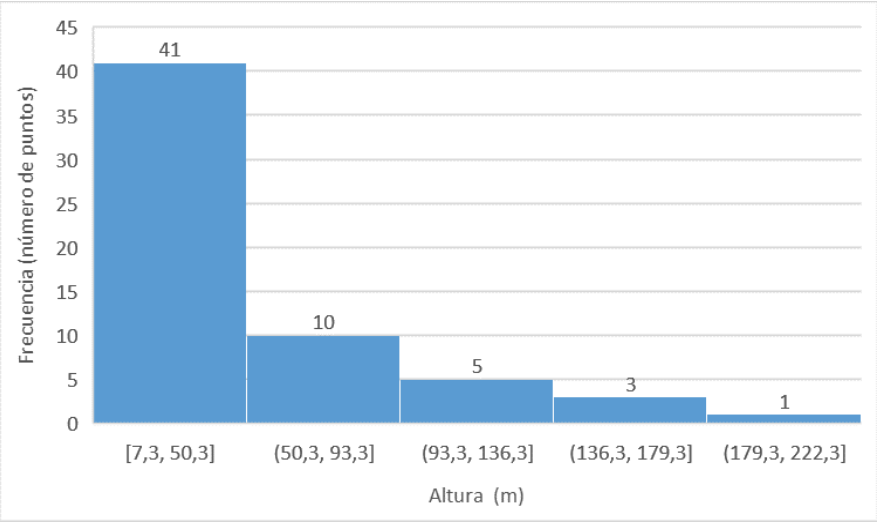


Figura 3. Histograma de elevaciones de los puntos de la Red de Control Vertical IGAC

Los datos presentan una distribución sesgada a la derecha, lo que indica una concentración de datos en valores bajos, con pocos valores muy altos que estiran la distribución de frecuencia de valores de altura, 51 de las muestras de puntos se agrupan en valores de altura por debajo de 100 metros, en zonas de planicie. Los valores de altura

mayores a 100 presentan discrepancias notables, en especial dos ubicaciones las cuales presentan una discrepancia mayor a 100 metros de diferencia. (ver valores en Anexo)

3.1.2 Diferencias altimétricas

La evaluación comparativa de los tres modelos digitales de elevación (MDE) frente a los puntos de la red de control vertical permitió identificar variaciones significativas en la representación altimétrica del área de estudio. En términos del error medio (ME), el producto Copernicus GLO-30 registró un valor de -2.10 m, mientras que FABDEM y ANADEM alcanzaron -3.07 m y -2.59 m, respectivamente. Los valores negativos evidencian un sesgo de subestimación de la cota altimétrica de aproximadamente dos metros en el modelo con mejor desempeño (Copernicus DEM).

Tabla 4. Resultados de indicadores estadisticos

DEM	N	ME	MAE	RMSE
FABDEM	60	-3,07	4,99	20,91
Copernicus	60	-2,10	5,44	20,34
ANADEM	60	-2,59	5,09	20,49

Por su parte, los resultados del error absoluto medio (MAE) indican desviaciones promedio respecto a la referencia de 4.99 m para FABDEM, 5.09 m para ANADEM y 5.44 m para Copernicus GLO-30. Asimismo, la raíz del error cuadrático medio (RMSE) reflejó una magnitud global de discrepancias cercana a los 20 metros para todos los modelos evaluados. Dichas discrepancias se aprecian con mayor claridad en la distribución espacial de los errores y en los diagramas de dispersión correspondientes (Figura 4 y 5).

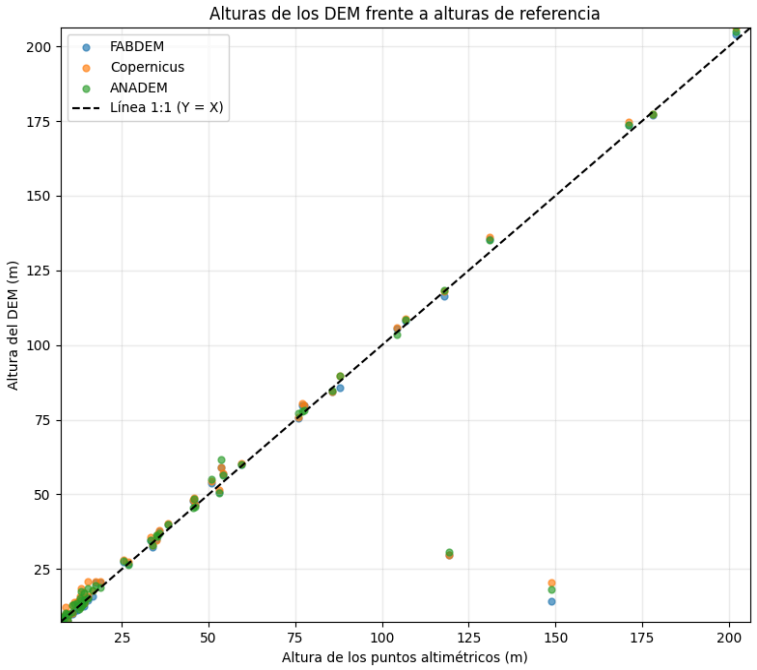


Figura 4. Alturas de los DEM frente a los valores de altura de referencia

La figura 4 visualiza los valores de altura para la muestra de puntos en cada uno de los tres diferentes MDE utilizando como referencia los datos de altura provenientes de RCV. La línea central 1:1 representa una concordancia perfecta entre los valores de referencia y los DEM, cuanto más cerca estén los puntos de la línea, menor será la diferencia entre las alturas del DEM y las referencias altimétricas.

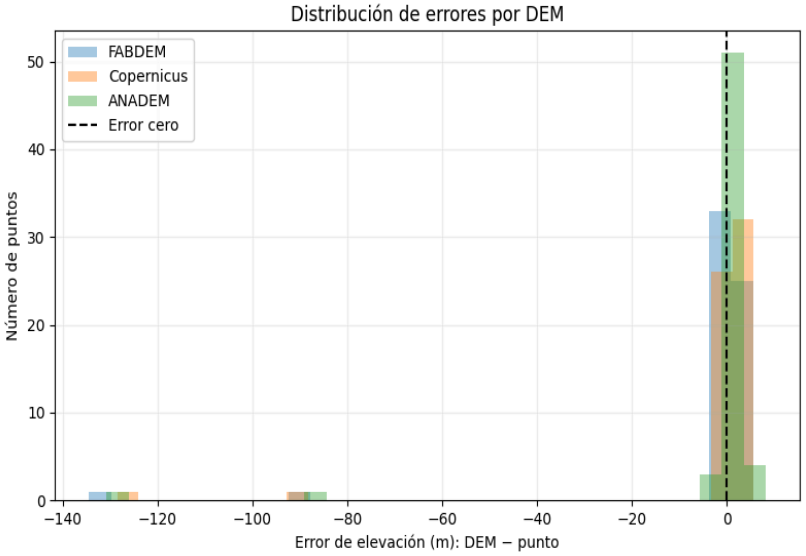


Figura 5: Histograma de errores

La distribución espacial del error altimétrico con respecto a los puntos de referencia geodésica de la Red de Control Vertical del IGAC se ilustra en la Figura 6. Del análisis espacial de dichos errores se deduce un patrón según la localización geográfica dentro de la cuenca. (Figura 6). En la periferia del área de estudio, los tres Modelos Digitales de Elevación (MDE) muestran errores positivos superiores a 4 m, lo cual evidencia una tendencia generalizada a la sobreestimación de la cota. Al evaluar las estaciones ubicadas en la parte central de la planicie aluvial, los modelos tienden a subestimar la elevación del terreno, registrando desviaciones negativas cercanas a -4 m.

Se identifican observaciones anómalas en los tres productos de elevación que incrementan significativamente las métricas de error global (como el RMSE), la mayoría asociadas a discrepancias notables en muestras puntuales. (Figura 6.d)

Al comparar el comportamiento individual de los modelos, FABDEM destaca por presentar una distribución del error fuertemente centrada en 0 m, lo que refleja un sesgo mínimo. Por su parte, Copernicus DEM exhibe una tendencia moderada a la sobreestimación altimétrica en la cuenca, mientras que ANADEM mantiene una distribución de errores equilibrada y cercana a cero.

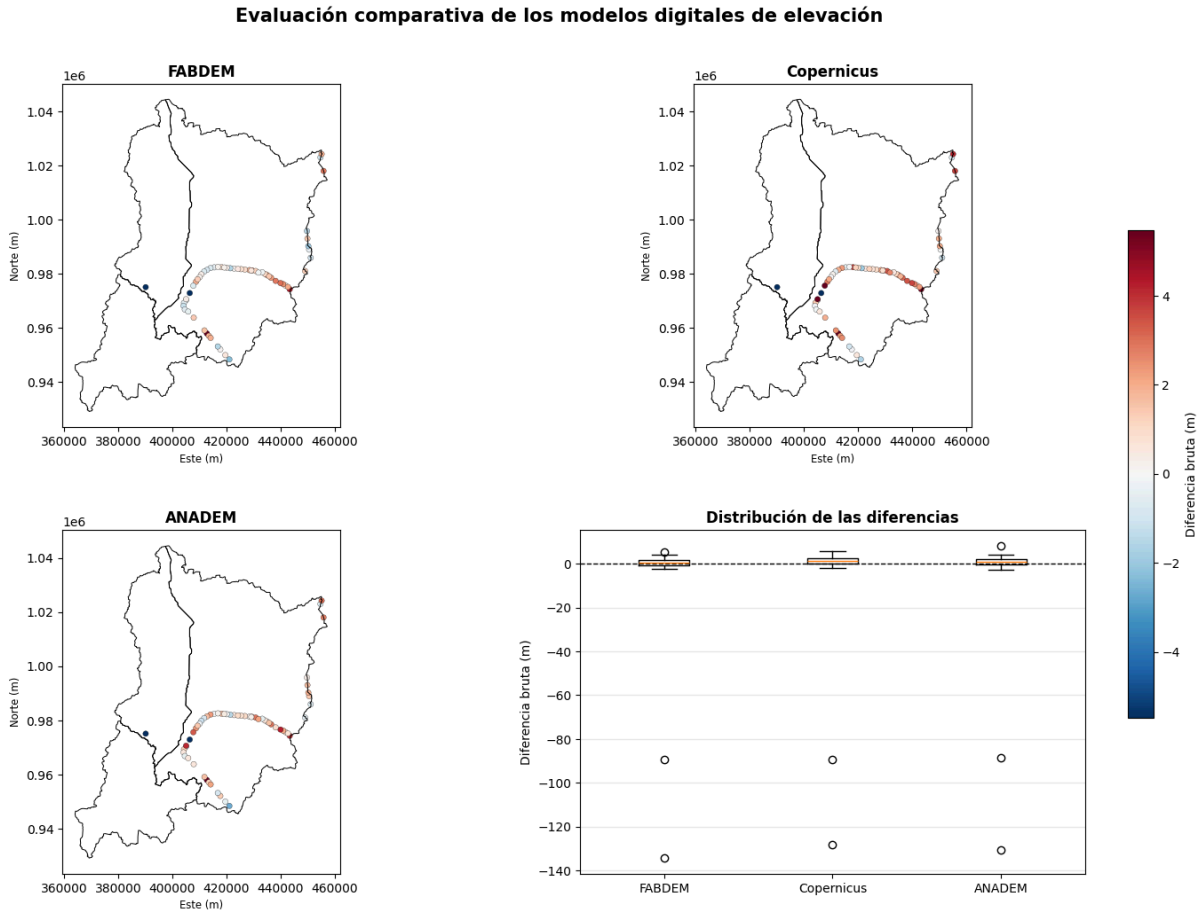


Figura 6. Distribución espacial del error altimétrico utilizando como referencia la RPCV. 6.a) FABDEM. 6.b) Copernicus DEM 6.c) ANAMEM 6.d) Caja de bigotes de error respecto a la altura de referencia

3.2 Parte 2. Evaluación de desempeño de modelos de susceptibilidad

3.2.1 Distribución espacial y características del inventario de inundaciones

El raster de inundaciones obtenido a partir de imágenes Sentinel-1 identificó una superficie inundada de 43604,46 ha, distribuida principalmente en las inmediaciones del Río Sinú como se observa en la Figura 7. La distribución espacial evidencia un patrón vertical a lo largo del cauce, lo que sugiere una relación con desbordamientos. El numero identificado de pixeles para el inventario binario fue, No inundado: 6,035,219 píxeles; Inundado: 484,494 píxeles.

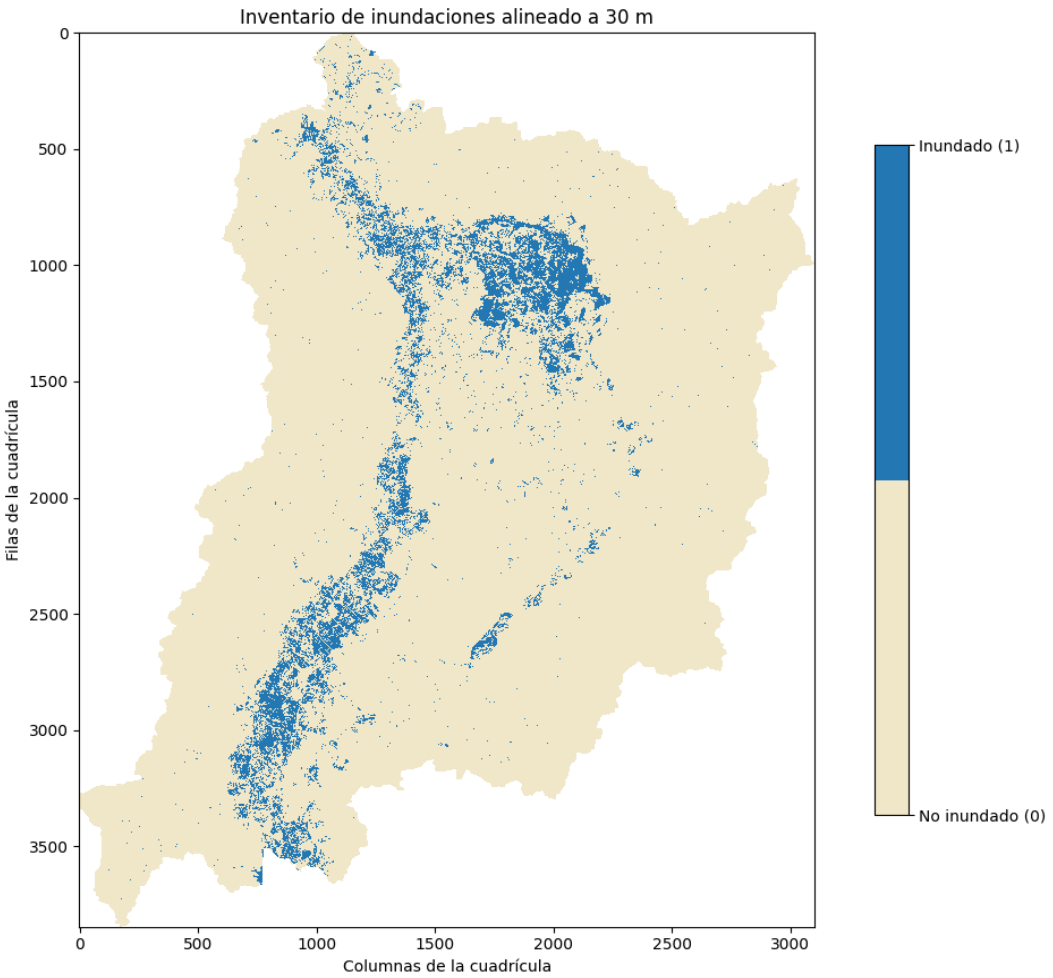


Figura 7. Distribución espacial de clases identificadas, inundado o no inundado.

El inventario generado representa las condiciones de inundación correspondientes al evento de Febrero de 2026, a partir de dos imágenes Sentinel-1. Su distribución permite identificar la predominancia de estancamientos al largo del cauce principal. Sin embargo, la representatividad de este inventario está condicionada por las características del evento, así como la resolución de las imágenes SAR. Adicionalmente, factores como la vegetación y presencia de otras infraestructuras pueden generar errores de detección, por lo que los resultados deben interpretarse como una representación de un evento específico y no como la totalidad de las condiciones de inundación de la planicie.

3.2.2 Entrenamiento de Modelos

El entrenamiento del algoritmo Random Forrest se llevó a cabo con 60% del conjunto de datos de muestras. Adicionalmente, el entrenamiento tomo en cuenta 5 configuraciones de hiperparámetros sobre cada una de las tres clases de datos de variables predictoras geomorfológicas obtenidas de cada DEM. Se visualiza cada muestra del modelo en la figura 8.

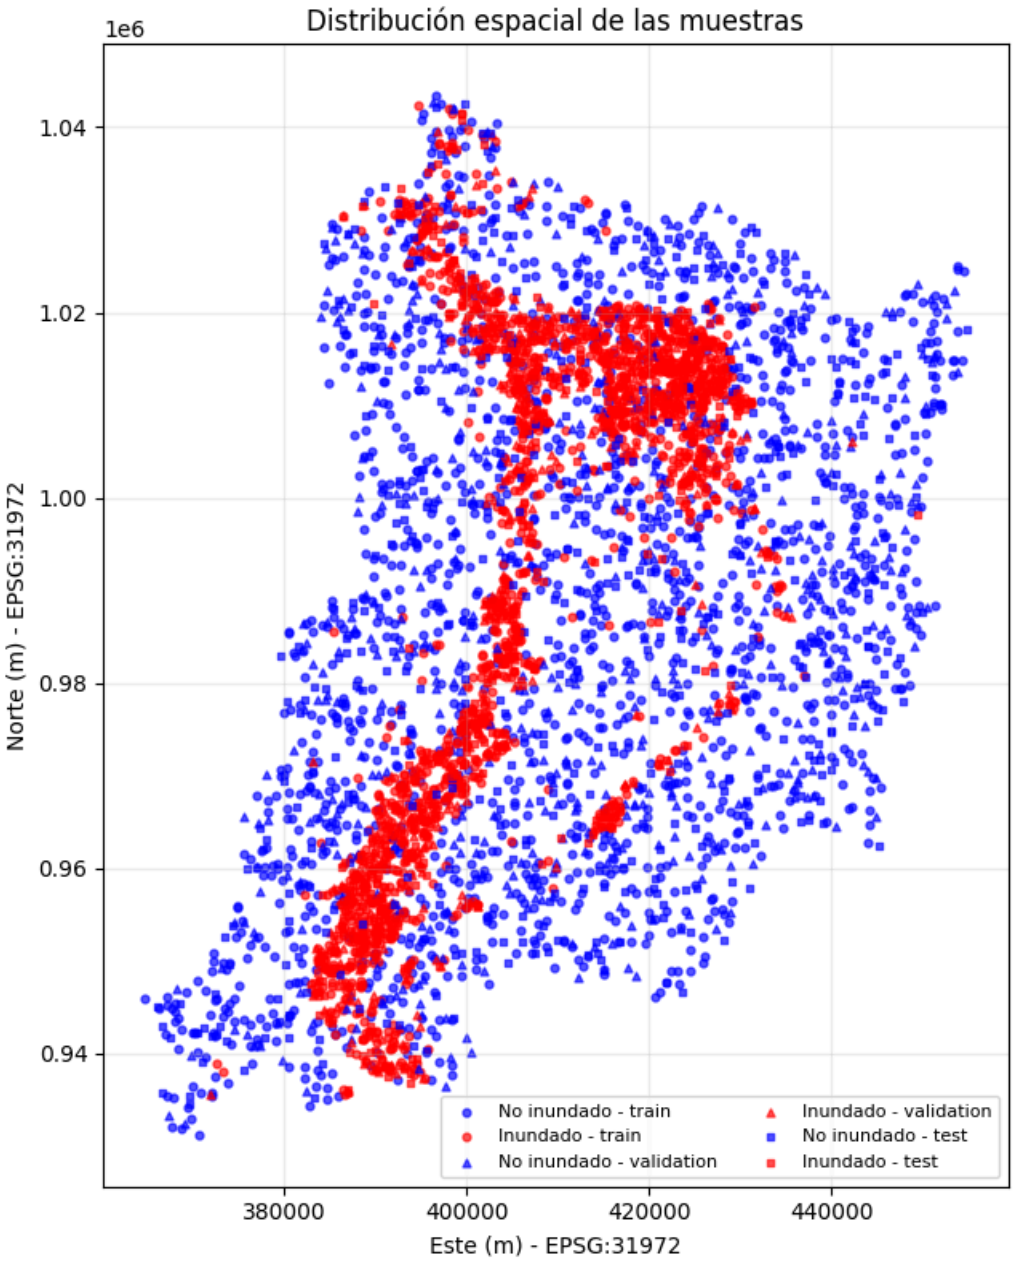


Figura 8. Distribución espacial de clases muestras del conjunto de datos. Muestra datos de entrenamiento, validación y prueba.

3.2.3 Desempeño de los modelos Random Forest con 5 configuraciones de hiperparámetros

Para cada modelo digital de elevación se evaluaron cinco configuraciones de hiperparámetros del algoritmo Random Forest, (Tabla 5), con el propósito de identificar las variaciones en su desempeño predictivo. En FABDEM, la configuración RF - FAB - 2 obtuvo el mejor resultado, con un ROC-AUC de 0,9355, F1-score de 0,8708, precisión de 0,8349 y sensibilidad de 0,9100. Por su parte, en Copernicus GLO-30, la configuración RF - COP – 5 presentó los mejores resultados (ROC AUC de 0,9342, F1 score de 0,8701) mientras que en ANADEM se destacó la configuración RF - ANA - 2 (ROC AUC de 0,9318, F1 score de 0,8735).

Tabla 5. Comparación de las cinco configuraciones de hiperparametros para modelo derivado de cada DEM

DEM	Codigo	n_estimators	max_depth	min_samples_leaf	max_features	Accuracy	Balanced accuracy	Precision	Recall	F1	ROC-AUC
ANA DEM	RF - ANA - 1	300		1	sqrt	0,8690	0,8690	0,8348	0,9200	0,8754	0,9314
ANA DEM	RF - ANA - 2	300	20	1	sqrt	0,8670	0,8670	0,8330	0,9180	0,8735	0,9318
ANA DEM	RF - ANA - 3	300	30	2	sqrt	0,8670	0,8670	0,8318	0,9200	0,8737	0,9312
ANA DEM	RF - ANA - 4	500		2	sqrt	0,8650	0,8650	0,8300	0,9180	0,8718	0,9317
ANA DEM	RF - ANA - 5	500	20	5	sqrt	0,8690	0,8690	0,8336	0,9220	0,8756	0,9313
Copernicus	RF - COP - 1	300		1	sqrt	0,8620	0,8620	0,8209	0,9260	0,8703	0,9336
Copernicus	RF - COP - 2	300	20	1	sqrt	0,8590	0,8590	0,8177	0,9240	0,8676	0,9339
Copernicus	RF - COP - 3	300	30	2	sqrt	0,8630	0,8630	0,8259	0,9200	0,8704	0,9339
Copernicus	RF - COP - 4	500		2	sqrt	0,8620	0,8620	0,8244	0,9200	0,8696	0,9345
Copernicus	RF - COP - 5	500	20	5	sqrt	0,8620	0,8620	0,8221	0,9240	0,8701	0,9342
FABDEM	RF - FAB - 1	300		1	sqrt	0,8630	0,8630	0,8355	0,9040	0,8684	0,9341
FABDEM	RF - FAB - 2	300	20	1	sqrt	0,8650	0,8650	0,8349	0,9100	0,8708	0,9355
FABDEM	RF - FAB - 3	300	30	2	sqrt	0,8600	0,8600	0,8321	0,9020	0,8656	0,9347
FABDEM	RF - FAB - 4	500		2	sqrt	0,8650	0,8650	0,8386	0,9040	0,8701	0,9352
FABDEM	RF - FAB - 5	500	20	5	sqrt	0,8610	0,8610	0,8349	0,9000	0,8662	0,9355

3.2.4 Comparación según el DEM utilizado

La comparación de los modelos construidos con FABDEM, Copernicus GLO-30 y ANADEM evidenció diferencias de **0,7 %** en su desempeño. El modelo basado en FABDEM obtuvo los mejores resultados, con un ROC-AUC de 0,9304 y un F1-score de 0,8634, mientras que ANADEM presentó los valores más bajos (ROC-AUC de 0,9226 y un F1-score de 0,8571. Estas diferencias podrían estar relacionadas con la representación altimétrica y geomorfológica de cada MDE. Este comportamiento es consistente con los resultados de la evaluación altimétrica, donde el MDE FABDEM presentó una distribución equilibrada de errores. Lo anterior permite discutir la influencia de la fuente de elevación en el modelamiento de susceptibilidad.

Tabla 6. Desempeño de modelos ante el conjunto de pruebas.

DEM	Accuracy	Balanced accuracy	Precision	Recall	F1	ROC-AUC
FABDEM	0.856	0.856	0.8213	0.910	0.8634	0.9304
Copernicus DEM	0.866	0.866	0.8268	0.926	0.8736	0.9255
ANADEM	0.849	0.849	0.8133	0.906	0.8571	0.9226

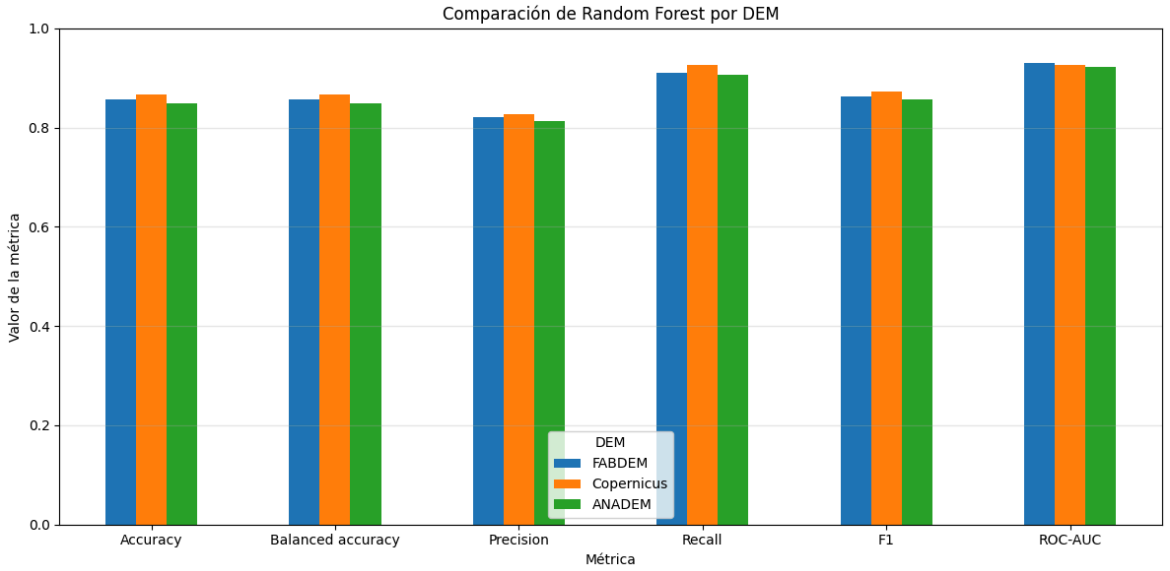


Figura 9. Gráfico comparativo del desempeño de los 3 modelos RF evaluados

3.2.5 Matrices de confusión y curvas ROC

Las matrices de confusión permitieron identificar diferencias en la clasificación de las zonas inundables y no inundables, particularmente en términos de falsos positivos y falsos negativos. Estos resultados evidencian que el modelo que presentó mejor comportamiento fue Copernicus DEM, que presentó el menor número de falsos positivos y falsos negativos

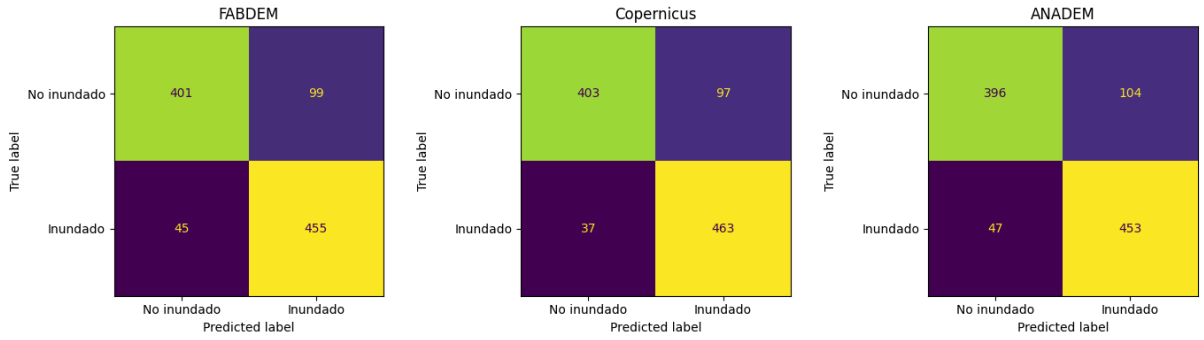


Figura 10. Matrices de confusión para tres modelos RF evaluados

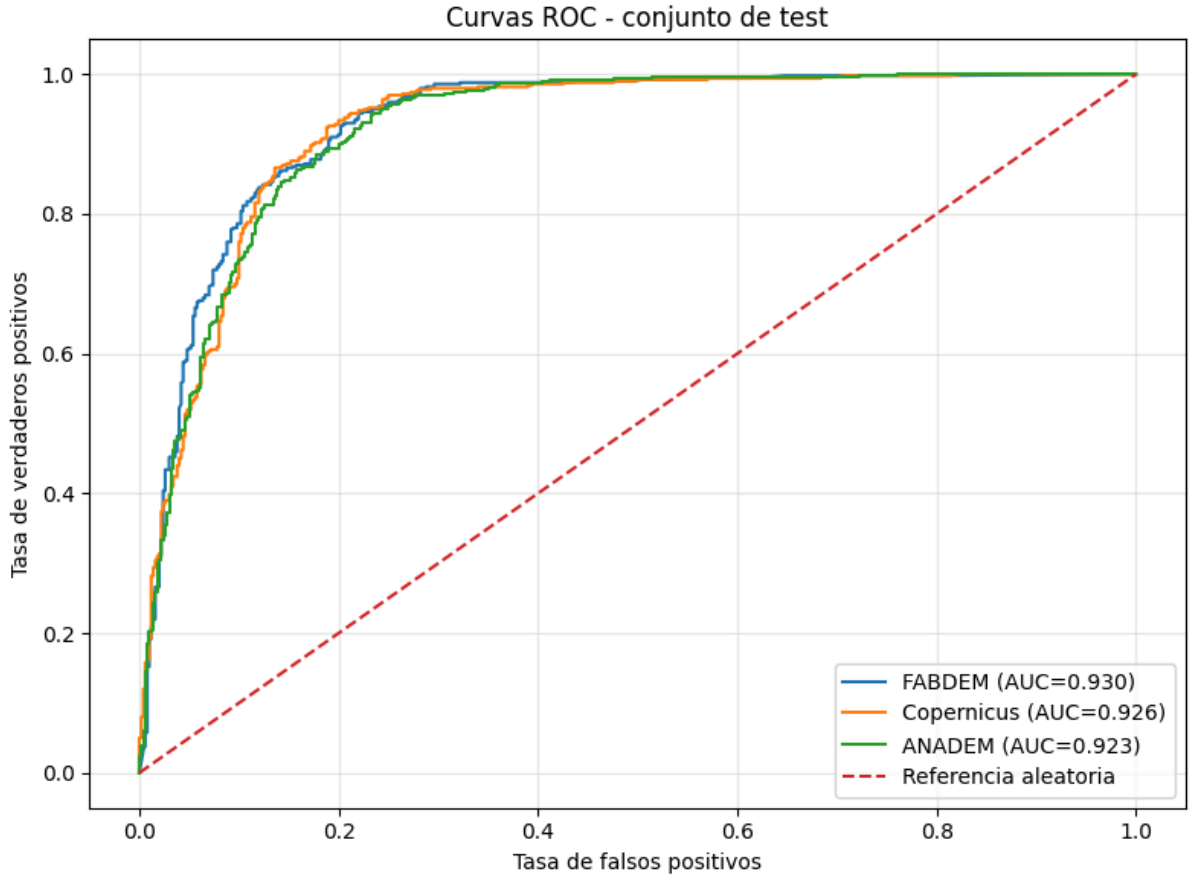


Figura 11. Gráfico comparativo del desempeño de los 3 modelos RF evaluados

3.2.6 Importancia de las variables en los modelos Random Forest

El análisis de importancia de variables permitió identificar la contribución relativa de cada variable en los modelos Random Forest construidos a partir de los tres modelos digitales de elevación. Para FABDEM, las variables con mayor importancia fueron HAND, Elevation y TRI, con valores de 0,2622 , 0,1957 y 0,126, respectivamente. En Copernicus GLO-30, se destacaron las mismas variables, HAND, Elvation y TRI, al igual que en el modelo de ANADEM, donde las mayores contribuciones corresponden a HAND, Elvation y TRI. Por otra parte, las variables con menor importancia fueron TPI, Curvature y Flow Accumulation en los tres modelos. Estos resultados evidencian un comportamiento similar del modelo en cuanto la asignación de importancia de la variables, variando solo en el valor de la contribución de los predictores a la clasificación de las zonas inundables y no inundables.

Las diferencias en la importancia de las variables sugieren que la representación del relieve influye en la contribución de los predictores al modelamiento de susceptibilidad. En particular, la variable HAND presentó una mayor importancia en los tres modelos, lo que podría estar relacionado con la representación de la superficie del suelo en función del desnivel con su punto de drenaje más cercano.

Tabla 7. Análisis de importancia de Variables por cada modelo derivado de DEM

DEM	Elevation	Slope	HAND	Flow Accumulation	DistRiver	TWI	Curvature	TPI	TRI
FABDEM	0.1957	0.0971	0.2622	0.0294	0.1179	0.0713	0.0466	0.0537	0.1260
Copernicus DEM	0.2062	0.1003	0.2809	0.0207	0.1178	0.0630	0.0418	0.0475	0.1219
ANADEM	0.2343	0.0982	0.2813	0.0176	0.1215	0.0533	0.0308	0.0385	0.1246

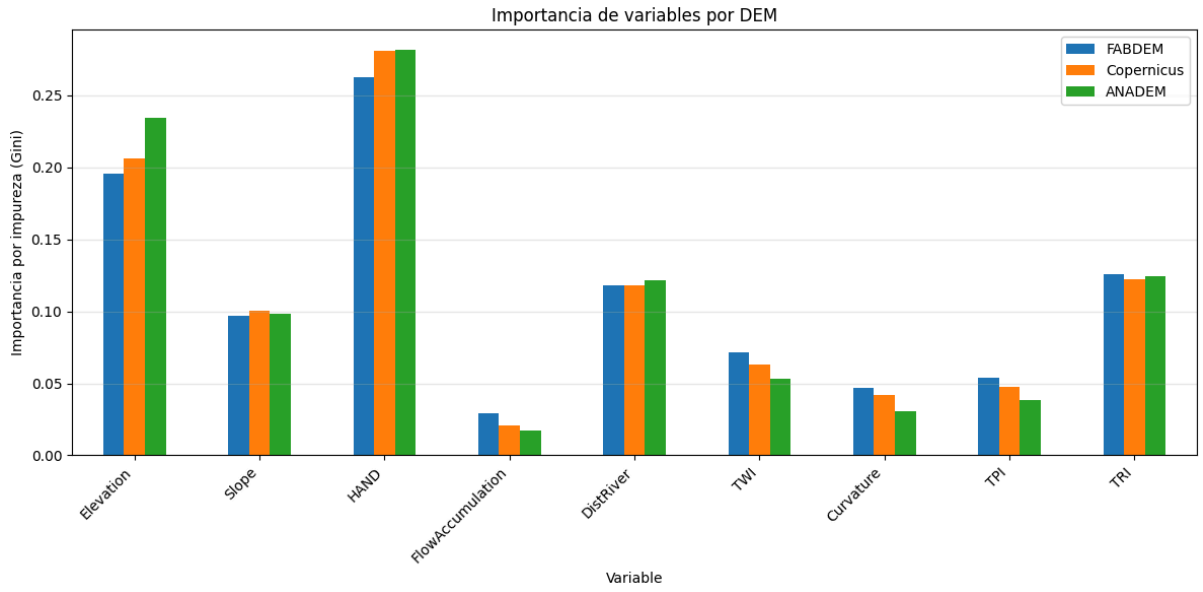


Figura 12. Gráfico comparativo de la importancia de las variables por cada DEM

4. Discusión

4.1 Parte 1. Comparación de los DEM en condiciones homogéneas

Las diferencias identificadas en cuanto a alturas pueden estar relacionadas con las características de adquisición, procesamiento y representación de cada modelo. Teniendo en cuenta, que para los modelos DEM se utilizó el mismo sistema de coordenadas vertical basado en el Elipsoide EGM2008, habría que entrar a analizar si la red de puntos de control vertical del IGAC presenta discrepancias en cuanto al elipsoide utilizado como referencia, ya que hay una sobrestimación constante de aproximadamente 2 metros para cualquier DEM según se vio reflejado en el índice ME. Estas variaciones son particularmente importantes en planicies aluviales, donde pequeñas diferencias altimétricas pueden modificar la representación de las condiciones topográficas analizadas, como argumenta Xu et al (2021)

La distribución espacial del error representa concordancia con los puntos disponibles como referencia, exceptuando 2 valores atípicos, los resultados no muestran necesariamente exactitud absoluta en toda la planicie aluvial, como se evidencia en los valores extremos. El error puede asociarse a la presencia de otras superficies, ya que el COPERNICUS DEM fue el que presentó mayor sobreestimación, lo que concuerda al ser un modelo digital de superficies. Esto concuerda con los estudios realizados por Toledo Salgado et al., (2026), donde Copernicus DEM obtuvo un RMSE más bajo y un ligero sesgo positivo.

En el proceso de evaluación altimétrica, se resalta el agrupamiento de los puntos disponibles para referencia. Esto puede ocasionar que los puntos cercanos entre sí no sean estadísticamente independientes ni ser una evaluación pertinente para los modelos. Como mejora del estudio se sugiere comparar con datos LiDAR vinculados al mismo elipsoide de referencia para abarcar completamente la zona de estudio.

4.2 Parte 2. Evaluación de desempeño de modelos de susceptibilidad

El inventario de inundaciones utilizado para este estudio representa las características de un solo evento de inundación, por lo que los modelos elaborados con esta variable objetivo pueden contener un sesgo. Así mismo, este inventario fue generado a partir de imágenes Sentinel-1 mediante técnicas de umbralización automática. Aunque este enfoque ha demostrado ser efectivo para la identificación de áreas inundadas (Thi An et al., 2025; Tran et al., 2022) , los resultados podrían verse afectados por la selección temporal de las imágenes, las condiciones de humedad previas al evento y la presencia de coberturas con respuestas de retrodispersión similares al agua, como por ejemplo la presencia de humedales y ciénagas. Por esta razón, futuras investigaciones podrían comparar el inventario obtenido con registros históricos de inundaciones.

El modelo Random Forest obtuvo un buen desempeño general en términos de clasificación, alcanzando una exactitud superior al 90 % para cada modelo derivado de los conjuntos de variables. El modelo derivado de datos FABDEM demostró ser el de mejores métricas de predicción (ROC - AUC de 0.9304), seguido de Copernicus DEM, ANADEM no demostró ser mejor aunque fue diseñado para Suramérica, lo que concuerda con los estudios realizados por Toledo Salgado et al., (2026).

Sin embargo, al evaluar la capacidad de los modelos para identificar correctamente los casos de inundación y no inundación, el modelo derivado de Copernicus GLO-30 presentó el mejor desempeño, con un F1-score de 0,8736. Este resultado podría estar relacionado con las características de precisión vertical del modelo y su comportamiento frente a las condiciones morfológicas del terreno. En este sentido, Helmy et al. (2026) señalan que la precisión vertical de los modelos digitales de elevación varía en función del contexto morfológico. Asimismo, la evaluación realizada en este estudio y en el de Helmy et al, mostró que Copernicus GLO-30 presentó un bajo sesgo en comparación con los datos de referencia, lo que podría favorecer una representación más consistente de las características topográficas utilizadas como variables predictoras.

El análisis de importancia de variables evidenció que la altura sobre el drenaje más cercano (HAND), la elevación, el índice de rugosidad topográfica y la distancia a la red de drenaje, constituyen los factores con mayor influencia sobre la ocurrencia de inundaciones. Cabe resaltar que en este estudio únicamente se tomaron variables geomorfológicas e hidrológicas. Este comportamiento resulta medianamente coherente, varios estudios (Rahman et al., 2025; Halder et al., 2024) señalan a la proximidad al drenaje como la variable más importante, junto a la elevación ya que la proximidad a los cauces favorece la exposición a desbordamientos, mientras que las zonas de menor elevación relativa y menor pendiente presentan una mayor tendencia a la acumulación temporal de agua.

5. Conclusiones

Los modelos digitales de elevación (MDE) a escala global siguen siendo valiosos para los estudios de inundaciones en regiones con pocos datos. Sin embargo, su aplicación requiere considerar las incertidumbres verticales y horizontales asociadas a la generación de datos. Es recomendable seguir los estudios con futuros MDE para garantizar una representatividad acertada de la superficie del terreno, en especial cuando se requieren aplicaciones con MDT.

6. Disponibilidad de datos

El código fuente completo, los scripts del flujo de trabajo y las tablas derivadas están disponibles públicamente en el repositorio de GitHub:

https://github.com/savelosab-cloud/susceptibilidad-inundaciones-rio-sinu.git

Cualquier consulta puede dirigirse al autor a través del correo institucional: savelosab@unal.educo

5. ANEXOS

A.1 TABLAS

Tabla A.1. Elevaciones registradas para los 60 puntos de referencia que se usan en la evaluacion altimetría.*

ID	Z_ Referencia	Z_ FANDOM	Z_ Copernicus	Z_ANADEM	D_FABDEM	D_Copernicus	D_ANADEM
53	7,25	7,52	8,47	7,69	0,27	1,21	0,44
49	7,71	8,66	8,77	8,71	0,95	1,06	1,00
50	7,87	8,72	8,56	8,66	0,85	0,69	0,79
52	8,22	8,53	9,27	8,17	0,31	1,04	-0,05
6	8,58	8,73	9,08	9,14	0,15	0,50	0,56
35	8,66	9,52	12,40	10,27	0,86	3,74	1,61
51	9,10	9,60	10,31	10,10	0,50	1,21	1,00
30	9,25	7,68	7,36	7,84	-1,57	-1,90	-1,41
36	9,52	9,77	9,47	9,76	0,25	-0,04	0,24
21	10,78	10,02	13,06	13,06	-0,76	2,28	2,28
20	10,81	10,31	10,35	10,64	-0,50	-0,46	-0,17
46	11,19	11,09	13,88	13,32	-0,10	2,70	2,13
22	12,08	11,24	14,06	13,70	-0,84	1,98	1,62
58	12,43	13,81	14,34	13,06	1,38	1,90	0,63
24	12,60	12,91	12,80	11,52	0,31	0,20	-1,08
23	12,92	12,21	12,35	12,13	-0,71	-0,57	-0,79
37	13,00	14,89	15,82	15,39	1,89	2,82	2,39
25	13,06	13,31	12,99	12,76	0,25	-0,07	-0,30
55	13,12	14,44	15,21	14,55	1,32	2,09	1,43
39	13,25	13,58	18,67	17,38	0,33	5,43	4,13
7	13,39	12,97	13,46	13,00	-0,42	0,07	-0,39
28	13,91	15,13	17,30	16,78	1,22	3,39	2,87
9	13,92	12,74	13,74	14,48	-1,18	-0,18	0,56
10	14,09	13,55	13,94	13,68	-0,54	-0,15	-0,41
11	14,14	13,72	14,69	14,72	-0,42	0,55	0,58
29	15,16	15,68	15,90	15,34	0,52	0,73	0,18
56	15,26	14,49	20,74	18,59	-0,77	5,48	3,33
8	16,51	15,96	17,94	17,79	-0,55	1,42	1,28
4	17,45	20,40	20,69	19,53	2,95	3,24	2,08
5	18,77	20,61	20,85	19,02	1,84	2,07	0,25
14	25,58	27,48	28,11	27,74	1,90	2,53	2,16
27	26,97	26,88	27,45	26,54	-0,09	0,47	-0,43
44	33,15	34,71	35,64	34,76	1,56	2,49	1,61
45	33,89	32,32	32,88	33,02	-1,57	-1,01	-0,87
15	34,89	34,99	34,71	36,22	0,10	-0,18	1,33
3	35,34	36,38	36,51	35,97	1,04	1,18	0,63
13	35,78	37,75	38,10	37,06	1,97	2,32	1,28
26	38,40	39,84	40,24	39,98	1,44	1,84	1,58
2	45,60	47,80	48,07	45,70	2,20	2,47	0,10
1	45,68	47,96	48,82	48,63	2,28	3,13	2,95
16	46,12	46,67	46,65	45,71	0,55	0,54	-0,41
41	50,75	53,79	54,38	54,95	3,04	3,63	4,20
17	53,04	50,74	51,42	50,38	-2,30	-1,62	-2,66
12	53,45	58,97	59,10	61,66	5,52	5,65	8,21
40	54,28	56,80	57,03	56,32	2,52	2,75	2,04
38	59,35	59,96	60,38	60,17	0,61	1,02	0,82
32	75,79	75,45	75,74	77,25	-0,34	-0,05	1,46
43	76,89	79,79	80,34	77,83	2,90	3,45	0,94
54	77,61	79,66	79,91	78,28	2,05	2,29	0,67
31	85,56	84,57	84,44	84,85	-0,99	-1,12	-0,71
33	87,72	85,78	89,70	89,69	-1,94	1,98	1,97
59	104,19	105,49	105,68	103,63	1,30	1,49	-0,56
47	106,67	108,02	108,68	108,31	1,35	2,01	1,64
34	117,97	116,53	118,14	118,29	-1,44	0,16	0,32
18	119,28	29,80	29,85	30,64	-89,48	-89,43	-88,64

48	131,12	135,38	136,24	135,10	4,26	5,12	3,98
19	148,78	14,36	20,34	18,06	-134,42	-128,44	-130,72
57	171,00	173,87	174,72	173,67	2,87	3,71	2,67
42	178,16	177,09	177,42	177,42	-1,07	-0,74	-0,74
60	202,08	204,02	206,21	205,11	1,94	4,13	3,03

*Nota: Los valores Z hacen referencia al valor original, los valores D hacen referencia a la resta respecto al valor de referencia

A.2 FIGURAS

Salidas Gráficas para variables derivadas por cada MDE.

A.2.1 Copernicus DEM

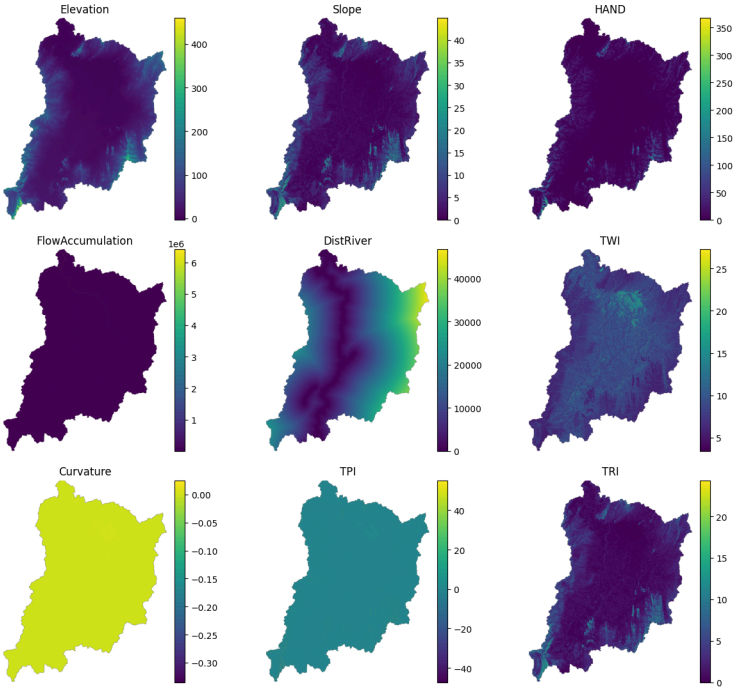


Figura A.2.1. Variables derivadas de COPERNICUS DEM para el área de estudio

A.2.2 FABDEM

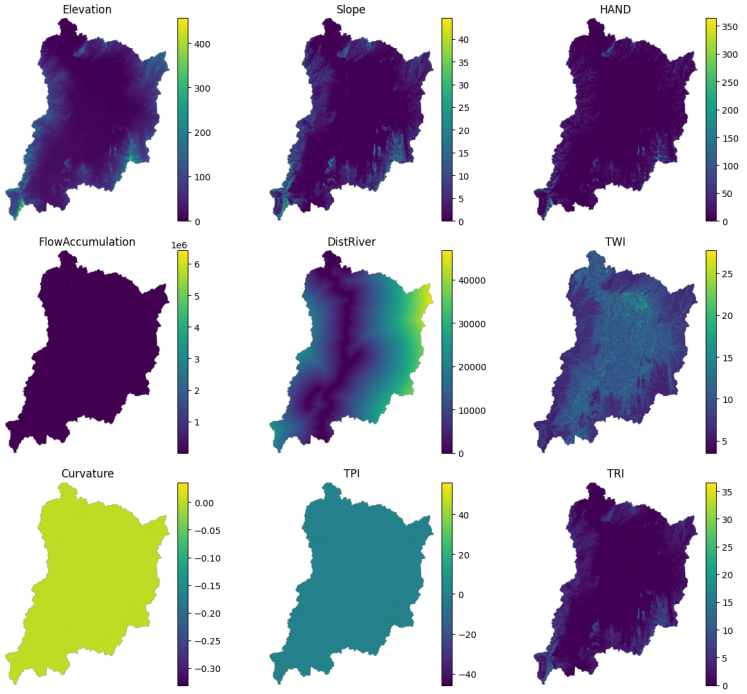


Figura A.2.2. Variables derivadas de FABDEM para el área de estudio

A.2.3 ANADEM

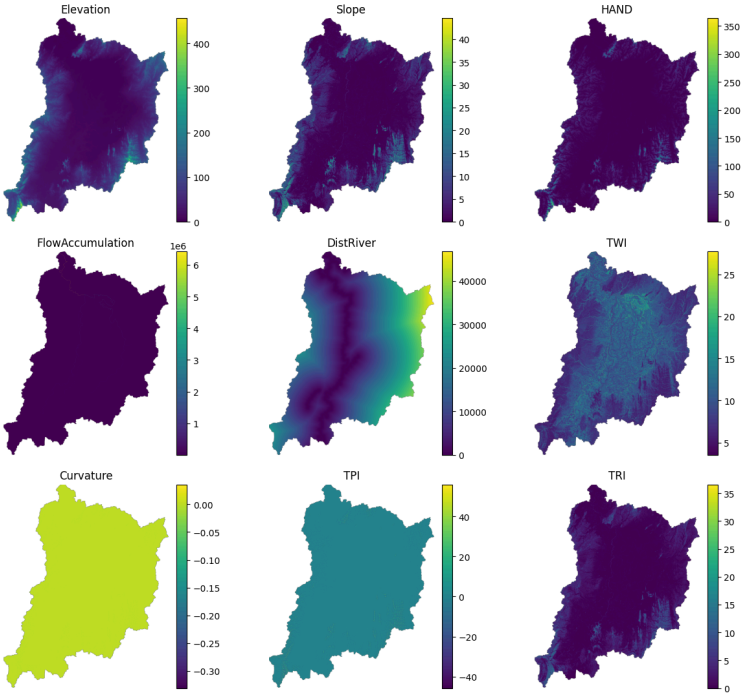


Figura A.2.3. Variables derivadas de ANADEM para el área de estudio

Referencias

Al-Sheriadeh, M. S., & Daqdouq, M. A. (2024). Robustness of machine learning algorithms to generate flood susceptibility maps for watersheds in Jordan. *Geomat Nat Hazards Risk*, *15*(1). https://doi.org/10.1080/19475705.2024.2378991

Arora, M., Setia, R., Singh, R., Singh, S. K., Kumar, S., & Pateriya, B. (2025). Mapping of flood inundated areas using earth observation data and cloud computing platform. *Journal of Atmospheric and Solar-Terrestrial Physics*, *274*, 106567. https://doi.org/10.1016/j.jastp.2025.106567

Avila-Aceves, E., Plata-Rocha, W., Monjardin-Armenta, S. A., & Rangel-Peraza, J. G. (2023). Geospatial modelling of floods: a literature review. *Stochastic Environmental Research and Risk Assessment 2023 37:11*, *37*(11), 4109–4128. https://doi.org/10.1007/S00477-023-02505-1

Bathe, K. D., & Patil, N. S. (2025). Flood Detection and Mapping: A Critical Review of Methods, Challenges and Future Prospects. *Journal of the Indian Society of Remote Sensing 2025 53:11*, *53*(11), 3511–3542. https://doi.org/10.1007/s12524-025-02277-x

Bielski, C., Lopez-Vazquez, C., Grohmann, C. H., Guth, P. L., Hawker, L., Gesch, D., Trevisani, S., Herrera-Cruz, V., Riazanoff, S., Corseaux, A., Reuter, H. I., & Strobl, P. (2024). Novel Approach for Ranking DEMs: Copernicus DEM Improves One Arc Second Open Global Topography. *IEEE Transactions on Geoscience and Remote Sensing*, *62*, 1–22. https://doi.org/10.1109/TGRS.2024.3368015

Carrera-Hernández, J. J. (2021). Not all DEMs are equal: An evaluation of six globally available 30 m resolution DEMs with geodetic benchmarks and LiDAR in Mexico. *Remote Sensing of Environment*, *261*, 112474. https://doi.org/10.1016/J.RSE.2021.112474

Gao, D., Wang, W., Yin, J., Yu, D., Lu, Y., Yuan, X., Li, M., & Yang, Y. (2026). Validation of flood inundation modelling using multi-source SAR imagery. *Water Research*, *296*. https://doi.org/10.1016/j.watres.2026.125590

Halder, K., Ghosh, A., Srivastava, A. K., Pal, S. C., Chatterjee, U., Bisai, D., Ewert, F., Gaiser, T., Islam, A. R. M. T., Alam, E., & Islam, M. K. (2024). SAR-driven flood inventory and multi-factor ensemble susceptibility modelling using machine learning frameworks. *Geomatics, Natural Hazards and Risk*, *15*(1). https://doi.org/10.1080/19475705.2024.2409202

Helmy, M., Mandanici, E., Vittuari, L., & Bitelli, G. (2026). Global Digital Terrain Models: Evaluation of vertical accuracy against different morphological contexts. *Progress in Physical Geography*, *50*(4), 640–654. https://doi.org/10.1177/03091333251406853;JOURNAL:JOURNAL:PPGA;SUBPAGE:STRING:ACCESS

Hossain, M. N., & Paul, P. (2019). Impacts of climatic variability on agriculture and options for adaptation in the Surma River basin, Bangladesh. *Environmental Monitoring and Assessment*, *191*(2), 111-. https://doi.org/10.1007/S10661-019-7256-Z/METRICS

Kaya, C. M., & Derin, L. (2023). Parameters and methods used in flood susceptibility mapping: a review. *Journal of Water and Climate Change*, *14*(6), 1935–1960. https://doi.org/10.2166/WCC.2023.035

Khan, T. I., Ananga, E., Landry, S., & Downs, J. (2026). Environmental and climatic drivers of flood susceptibility and their interactions at the global contexts. *Discover Geoscience 2026 4:1*, *4*(1), 238-. https://doi.org/10.1007/S44288-026-00610-6

Laipelt, L., Comini de Andrade, B., Collischonn, W., de Amorim Teixeira, A., Paiva, R. C. D. de, & Ruhoff, A. (2024). ANADEM: A Digital Terrain Model for South America. *Remote Sensing*, *16*(13). https://doi.org/10.3390/RS16132321

Long, G., Tantanee, S., Nusit, K., & Sooraksa, P. (2025). Flood susceptibility mapping in the Yom River Basin, Thailand: stacking ensemble learning using multi-year flood inventory data. *Geocarto International*, *40*(1). https://doi.org/10.1080/10106049.2025.2461531;PAGE:STRING:ARTICLE/CHAPTER

Mesa-Mingorance, J. L., & Ariza-López, F. J. (2020). Accuracy Assessment of Digital Elevation Models (DEMs): A Critical Review of Practices of the Past Three Decades. *Remote Sensing 2020, Vol. 12, Page 2630*, *12*(16), 2630. https://doi.org/10.3390/RS12162630

Rahman, Z. U., Zhang, M., Chen, F., Ullah, S., Ahmad, M., Feroz, A., Danhassan, S. S., & Azzam, A.

(2025). Flood susceptibility mapping using supervised machine learning models: insights into predictors' significance and models' performance. *Geomatics, Natural Hazards and Risk*, *16*(1). https://doi.org/10.1080/19475705.2025.2516728

Riazi, M., Khosravi, K., Shahedi, K., Ahmad, S., Jun, C., Bateni, S. M., & Kazakis, N. (2023). Enhancing flood susceptibility modeling using multi-temporal SAR images, CHIRPS data, and hybrid machine learning algorithms. *Science of The Total Environment*, *871*, 162066. https://doi.org/10.1016/J.SCITOTENV.2023.162066

Toledo Salgado, S. R., da Silva Carvalho, E. M., Viseu, M. T., & de Oliveira, O. F. (2026). Comparative Analysis of Global DEMs for Dam-Break Flood Modeling and Inundation Mapping. *Water Resources Management 2026 40:3*, *40*(3), 98-. https://doi.org/10.1007/S11269-025-04427-9

Thi An, T., Ngoc Hanh, L., Hoang Son, N., Phuc Chi Lang, L., Thi Dieu, N., & van An, N. (2025). Monitoring Flood Dynamics in Hoa Vang District, Da Nang City Using SAR Remote Sensing and Google Earth Engine. *IOP Conference Series: Earth and Environmental Science*, *1501*(1), 012013. https://doi.org/10.1088/1755-1315/1501/1/012013

Tran, K. H., Menenti, M., & Jia, L. (2022). Surface Water Mapping and Flood Monitoring in the Mekong Delta Using Sentinel-1 SAR Time Series and Otsu Threshold. *Remote Sensing*, *14*. https://doi.org/10.3390/rs14225721

Xu, K., Fang, J., Fang, Y., Sun, Q., Wu, C., & Liu, M. (2021). The Importance of Digital Elevation Model Selection in Flood Simulation and a Proposed Method to Reduce DEM Errors: A Case Study in Shanghai. *International Journal of Disaster Risk Science 2021 12:6*, *12*(6), 890–902. https://doi.org/10.1007/S13753-021-00377-Z